

COUNCILia

Análisis de costos y planes

Costos, márgenes y pricing actualizado para México.

- Costo por turno
- COGS por plan
- Precios Plus/Pro en MXN
- Márgenes y sensibilidad
- Proyecciones por usuarios

Documento financiero operativo

Versión 1.1 · 2026

Tabla de contenidos

1 Anatomía de costo por turno (1 mensaje del usuario)

2 Costo promedio por usuario / mes (COGS)

3 Planes y precios (precios en MXN)

4 Detalle de planes

5 Proyecciones por número de usuarios

6 ¿GPT-4o para Pro vale la pena?

7 Supuestos y variables críticas

Estimaciones basadas en la arquitectura real del código (3 agentes paralelos, réplica, síntesis). Tipo de cambio referencia: \$17.50 MXN/USD · Mayo 2026

Nota clave: al mover voz de ElevenLabs a TTS nativo (Google / OpenAI), el COGS baja de forma drástica. Con esta configuración, el costo de voz deja de dominar por completo y el margen bruto de Plus/Pro mejora de forma sustancial.

1. Anatomía de costo por turno (1 mensaje del usuario)

Cada "turno" = 3 agentes en paralelo + réplica (60% prob.) · Síntesis: 1 llamada por chat al final

GPT-4o-mini (Plus / Pro) — Por turno: \$0.00073

Fase	Input tok	Output tok	Costo
3 agentes (paralelo)	3 300	165	\$0.00059
Réplica ×60%	720	42	\$0.00013
Síntesis (1×chat)	1 500	200	\$0.00035

Gemini 2.0 Flash (Free) — Por turno: \$0.00048

Fase	Input tok	Output tok	Costo
3 agentes (paralelo)	3 300	165	\$0.00040
Réplica ×60%	720	42	\$0.00009
Síntesis (1×chat)	1 500	200	\$0.00023

TTS nativo (Google / OpenAI) — referencia \$0.000015 por carácter

Agente	Palabras	Chars	Costo/click
Marco	~70	~385	\$0.0058
Elena	~60	~330	\$0.0050
Rafael	~25	~137	\$0.0021
Promedio	~52	~284	\$0.0043

Solo se genera audio si el usuario presiona "Escuchar".

2. Costo promedio por usuario / mes (COGS)

Supuestos: Free = 2 chats × 4 msg; Plus = 8 chats × 8 msg, 12% voz; Pro = 20 chats × 12 msg, 18% voz

Free — Gemini Flash · 2 chats/mes · 4 msg/chat

Componente	Costo/mes
LLM (Gemini Flash)	\$0.0043
TTS (Google / OpenAI)	\$0.0000
Supabase + Infra	\$0.0250
TOTAL	\$0.0293

Plus — GPT-4o-mini · 8 chats/mes · 8 msg/chat

Componente	Costo/mes
LLM (GPT-4o-mini)	\$0.0493
TTS (Google / OpenAI)	\$0.0605
Supabase + Infra	\$0.0800
TOTAL	\$0.1898

Pro — GPT-4o-mini · 20 chats/mes · 12 msg/chat

Componente	Costo/mes
LLM (GPT-4o-mini)	\$0.1814
TTS (Google / OpenAI)	\$0.3402
Supabase + Infra	\$0.1600
TOTAL	\$0.6816

3. Planes y precios (precios en MXN)

Margen bruto sobre COGS directo. No incluye salarios ni amortización de desarrollo.

Plan	Precio MXN/mes	Equiv. USD/mes	COGS/usuario (USD)	Margen bruto
Free	Gratis	Gratis	\$0.0293	Mktg
Plus	\$79 MXN	~\$4.51 USD	\$0.1898	96%
Pro	\$199 MXN	~\$11.37 USD	\$0.6816	94%

Nota: aun con precios más agresivos (\$79/\$199), los márgenes quedan muy altos porque el cambio de stack de voz reduce de forma fuerte el COGS por usuario.

4. Detalle de planes

Free — Gratis para siempre

Parámetro	Límite
Chats simultáneos	1 activo
Mensajes por chat	5
Historial guardado	Solo el último
Modelo LLM	Gemini Flash
Voz	No
Síntesis al cierre	Sí

COGS: \$0.0293/usuario·mes. Riesgo: usuarios que abren y cierran chats repetidamente — considera límite de 10 chats nuevos/mes.

Plus — \$79 MXN/mes (~\$4.51 USD)

Parámetro	Límite
Chats simultáneos	10
Mensajes por chat	20
Historial guardado	Últimos 10 chats
Modelo LLM	GPT-4o-mini
Voz (TTS nativo)	Sí — Google / OpenAI
Síntesis al cierre	Sí
Exportar chat	No

COGS: \$0.1898/usuario·mes · Margen bruto: **96%**. TTS = \$0.0605 (~32% del COGS).

Pro — \$199 MXN/mes (~\$11.37 USD)

Parámetro	Límite
Chats simultáneos	Sin límite
Mensajes por chat	Sin límite
Historial guardado	Todo el historial
Modelo LLM	GPT-4o-mini (+ síntesis GPT-4o opcional)
Voz (TTS nativo)	Sí — Google / OpenAI
Síntesis al cierre	Sí (modelo más potente)
Exportar chat	Sí (PDF / markdown)

COGS: \$0.6816/usuario·mes · Margen bruto: **94%**. TTS = \$0.3402 (~50% del COGS).

5. Proyecciones por número de usuarios

Mix asumido: 70% Free · 22% Plus (\$79 MXN/mes) · 8% Pro (\$199 MXN/mes) Solo COGS variables — sin salarios ni hosting base.

1,000 usuarios → 700 Free · 220 Plus · 80 Pro

Métrica	MXN/mes	USD/mes
Ingresos brutos	\$33,300	\$1,903
COGS total	\$2,044	\$117
Utilidad bruta	\$31,256	\$1,786
Margen bruto	94%	—

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$28	\$497	24%

Componente de costo	USD/mes	MXN/mes	% del COGS
TTS (Google / OpenAI)	\$41	\$709	35%
Supabase + Infra	\$48	\$838	41%
COGS TOTAL	\$117	\$2,044	100%

5,000 usuarios → 3,500 Free · 1,100 Plus · 400 Pro

Métrica	MXN/mes	USD/mes
Ingresos brutos	\$166,500	\$9,514
COGS total	\$10,222	\$584
Utilidad bruta	\$156,278	\$8,930
Margen bruto	94%	—

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$142	\$2,485	24%
TTS (Google / OpenAI)	\$203	\$3,546	35%
Supabase + Infra	\$240	\$4,191	41%
COGS TOTAL	\$584	\$10,222	100%

10,000 usuarios → 7,000 Free · 2,200 Plus · 800 Pro

Métrica	MXN/mes	USD/mes
Ingresos brutos	\$333,000	\$19,029
COGS total	\$20,443	\$1,168
Utilidad bruta	\$312,557	\$17,860
Margen bruto	94%	—

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$284	\$4,970	24%
TTS (Google / OpenAI)	\$405	\$7,091	35%
Supabase + Infra	\$479	\$8,383	41%
COGS TOTAL	\$1,168	\$20,443	100%

Supabase: el plan Free soporta hasta 50,000 MAU sin costo adicional. A 10,000 usuarios estamos dentro del tier gratuito. El costo de DB se vuelve real por encima de 50k MAU (~\$25 USD/mes por Supabase Pro).

Costos NO incluidos: Hosting/servidor (Vercel/Railway ~\$20-50 USD/mes), dominio (~\$15 USD/año), soporte al cliente, salarios del equipo. El COGS aquí refleja solo APIs de IA e infraestructura de datos.

6. ¿GPT-4o para Pro vale la pena?

GPT-4o cuesta ~16× más que gpt-4o-mini. Con Pro en \$199 MXN/mes (~\$11.37 USD), sigue siendo rentable, pero hay que controlar alcance.

Escenario Pro	LLM / usuario·mes	COGS total	Margen a \$11.37 USD/mes
Solo GPT-4o-mini ■	\$0.181	\$0.682	94%

Escenario Pro	LLM / usuario·mes	COGS total	Margen a \$11.37 USD/mes
Síntesis con GPT-4o (1 llamada/chat) ■■	\$0.285	\$0.785	93%
Todo GPT-4o (posturas + réplica + síntesis) ■	\$2.903	\$3.403	70%

Recomendación: mantener GPT-4o-mini para posturas y réplica; usar GPT-4o solo en síntesis para Pro si buscas mayor calidad de cierre.

7. Supuestos y variables críticas

Lo que puede encarecer el costo

Variable	Impacto
Usuarios Free que generan muchos chats nuevos	Alto
Uso masivo de voz en Plus/Pro	Medio-Alto (~50% del COGS Pro)
Chats con historial largo (>15 mensajes)	Medio
Síntesis larga / reintentos	Bajo
Supabase por encima de 50k MAU	Medio

Lo que puede abaratar

Táctica	Ahorro estimado
Caché de system prompts (OpenAI Prompt Caching)	~50% en input tokens
Limitar historial en contexto a últimos N turnos	20–40% en input
TTS nativo (Google/OpenAI) vs ElevenLabs	~92% menos costo de voz por carácter
Rate-limiting conservador en Free	Protege contra abuso
Gemini para Free (ya en código)	~33% vs GPT-4o-mini

*Cálculos: gpt-4o-mini \$0.15/1M in · \$0.60/1M out · Gemini 2.0 Flash \$0.10/1M in · \$0.40/1M out · TTS
Google/OpenAI (supuesto blended) ~\$0.000015/char · Supabase Free hasta 50k MAU · \$17.50
MXN/USD · Mayo 2026*