

Análisis de costos · COUNCILia

Estimaciones basadas en la arquitectura real del código (3 agentes paralelos, réplica, síntesis).
Tipo de cambio referencia: \$17.50 MXN/USD · Mayo 2026

El costo más grande no es el LLM — es ElevenLabs. A escala, la voz sintética puede representar el 60–75% del COGS de un usuario Plus/Pro activo. El modelo GPT-4o-mini es sorprendentemente barato: ~\$0.00073 por turno completo de 3 agentes + réplica.

1. Anatomía de costo por turno (1 mensaje del usuario)

Cada "turno" = 3 agentes en paralelo + réplica (60% prob.) · Síntesis: 1 llamada por chat al final

GPT-4o-mini (Plus / Pro) — Por turno: \$0.00073

Fase	Input tok	Output tok	Costo
3 agentes (paralelo)	3 300	165	\$0.00059
Réplica ×60%	720	42	\$0.00013
Síntesis (1×chat)	1 500	200	\$0.00035

Gemini 2.0 Flash (Free) — Por turno: \$0.00048

Fase	Input tok	Output tok	Costo
3 agentes (paralelo)	3 300	165	\$0.00040
Réplica ×60%	720	42	\$0.00009
Síntesis (1×chat)	1 500	200	\$0.00023

ElevenLabs eleven_v3 — \$0.0002 por carácter (~escala Creator+)

Agente	Palabras	Chars	Costo/click
Marco	~70	~385	\$0.0770
Elena	~60	~330	\$0.0660
Rafael	~25	~137	\$0.0274
Promedio	~52	~284	\$0.0568

Solo se genera audio si el usuario presiona "Escuchar". Modelo: eleven_v3.

2. Costo promedio por usuario / mes (COGS)

Supuestos: Free = 2 chats × 4 msg; Plus = 8 chats × 8 msg, 12% voz; Pro = 20 chats × 12 msg, 18% voz

Free — Gemini Flash · 2 chats/mes · 4 msg/chat

Componente	Costo/mes
LLM (Gemini Flash)	\$0.0043
ElevenLabs	\$0.0000
Supabase + Infra	\$0.0250
TOTAL	\$0.029

Plus — GPT-4o-mini · 8 chats/mes · 8 msg/chat

Componente	Costo/mes
LLM (GPT-4o-mini)	\$0.0493
ElevenLabs	\$0.8064

Supabase + Infra	\$0.0800
TOTAL	\$0.936

Pro — GPT-4o-mini · 20 chats/mes · 12 msg/chat

Componente	Costo/mes
LLM (GPT-4o-mini)	\$0.1814
ElevenLabs	\$4.5360
Supabase + Infra	\$0.1600
TOTAL	\$4.877

3. Planes y precios (precios en MXN)

Margen bruto sobre COGS directo. No incluye salarios ni amortización de desarrollo.

\$0 Free / mes Para siempre	\$85 Plus / mes MXN · "H \$4.86 USD	\$210 Pro / mes MXN · "H \$12.00 USD
--	--	---

Plan	Precio MXN/mes	Equiv. USD/mes	COGS/usuario (USD)	Margen bruto
Free	Gratis	Gratis	\$0.029	Mktg
Plus	\$85 MXN	\$4.86 USD	\$0.936	81%
Pro	\$210 MXN	\$12.00 USD	\$4.877	59%

Nota: El precio Pro más accesible (de \$420 a \$210 MXN) reduce el margen de 80% a 59%, pero hace el plan mucho más competitivo para el mercado mexicano. El margen sigue siendo positivo incluso para usuarios Pro activos con voz.

4. Detalle de planes

Free — Gratis para siempre

Parámetro	Límite
Chats simultáneos	1 activo
Mensajes por chat	5
Historial guardado	Solo el último
Modelo LLM	Gemini Flash
Voz (ElevenLabs)	No
Síntesis al cierre	Sí

COGS: \$0.029/usuario·mes. Riesgo: usuarios que abren y cierran chats repetidamente — considera límite de 10 chats nuevos/mes.

Plus — \$85 MXN/mes (~\$4.86 USD)

Parámetro	Límite
Chats simultáneos	10
Mensajes por chat	20
Historial guardado	Últimos 10 chats
Modelo LLM	GPT-4o-mini
Voz (ElevenLabs)	Sí — 3 voces por agente

Síntesis al cierre	Sí
Exportar chat	No

COGS: \$0.936/usuario·mes · Margen bruto: 81%. ElevenLabs = \$0.806 (86% del COGS).

Pro — \$210 MXN/mes (~\$12.00 USD)

Parámetro	Límite
Chats simultáneos	Sin límite
Mensajes por chat	Sin límite
Historial guardado	Todo el historial
Modelo LLM	GPT-4o-mini (+ síntesis GPT-4o)
Voz (ElevenLabs)	Sí — autoplay secuencial
Síntesis al cierre	Sí (modelo más potente)
Exportar chat	Sí (PDF / markdown)

COGS: \$4.877/usuario·mes · Margen bruto: 59%. ElevenLabs = \$4.536 (93% del COGS). A este precio el margen es más ajustado — monitorear uso de voz en Pro.

5. Proyecciones por número de usuarios

Mix asumido: 70% Free · 22% Plus (\$85 MXN/mes) · 8% Pro (\$210 MXN/mes). Solo COGS variables (sin salarios ni hosting base).

1,000 usuarios totales !' 700 Free · 220 Plus · 80 Pro

\$35,500 MXN Ingresos brutos/mes	\$10,790 MXN COGS total/mes	\$24,710 MXN Utilidad bruta/mes	70% Margen bruto
--	---------------------------------------	---	----------------------------

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$28 USD	\$496 MXN	5%
ElevenLabs (voz)	\$540 USD	\$9,455 MXN	88%
Supabase + Infra	\$48 USD	\$838 MXN	8%
COGS TOTAL	\$617 USD	\$10,790 MXN	100%

5,000 usuarios totales !' 3,500 Free · 1,100 Plus · 400 Pro

\$177,500 MXN Ingresos brutos/mes	\$53,949 MXN COGS total/mes	\$123,551 MXN Utilidad bruta/mes	70% Margen bruto
---	---------------------------------------	--	----------------------------

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$142 USD	\$2,482 MXN	5%
ElevenLabs (voz)	\$2,701 USD	\$47,275 MXN	88%
Supabase + Infra	\$240 USD	\$4,191 MXN	8%
COGS TOTAL	\$3,083 USD	\$53,949 MXN	100%

10,000 usuarios totales !' 7,000 Free · 2,200 Plus · 800 Pro

\$355,000 MXN Ingresos brutos/mes	\$107,897 MXN COGS total/mes	\$247,103 MXN Utilidad bruta/mes	70% Margen bruto
---	--	--	----------------------------

Componente de costo	USD/mes	MXN/mes	% del COGS
LLM (Gemini + GPT-4o-mini)	\$284 USD	\$4,964 MXN	5%
ElevenLabs (voz)	\$5,403 USD	\$94,550 MXN	88%
Supabase + Infra	\$479 USD	\$8,383 MXN	8%
COGS TOTAL	\$6,166 USD	\$107,897 MXN	100%

Supabase Free soporta hasta 50,000 MAU sin costo adicional. A 10,000 usuarios activos/mes estamos dentro del tier gratuito. El costo de DB se vuelve real por encima de 50k MAU (~\$25 USD/mes por Supabase Pro, más storage si crece el historial).

Costos NO incluidos en las proyecciones: hosting/servidor (Vercel/Railway ~\$20-50 USD/mes), dominio (~\$15 USD/año), soporte al cliente, salarios del equipo. El COGS aquí refleja solo APIs de IA e infraestructura de datos.

6. ¿GPT-4o para Pro vale la pena?

GPT-4o cuesta ~16× más que gpt-4o-mini. Para la síntesis final (1 llamada/chat) el impacto es mínimo. Para las 3 posturas iniciales el costo sube notablemente — especialmente crítico con el margen más ajustado del Pro.

Escenario Pro	LLM / usuario·mes	COGS total	Margen a \$12 USD/mes
Solo GPT-4o-mini	\$0.181	\$4.877	59%
Síntesis con GPT-4o (1 llamada/chat)	\$0.285	\$4.981	58%
Todo GPT-4o (posturas + réplica + síntesis)	\$2.903	\$7.599	37%

Con el margen Pro más ajustado (59%), usar GPT-4o en síntesis sigue siendo viable (58%). Usar GPT-4o en todo baja el margen a 37% — no recomendado.

7. Supuestos y variables críticas

Lo que puede encarecer el costo

Variable	Impacto
Usuarios Free que generan muchos chats nuevos	Alto
Uso masivo de voz en Plus/Pro	Alto (93% COGS Pro)
Chats con historial largo (>15 mensajes)	Medio
Síntesis larga / reintentos	Bajo
Supabase por encima de 50k MAU	Medio

Lo que puede abaratar

Táctica	Ahorro estimado
Caché de system prompts (OpenAI Prompt Caching)	~50% en input tokens
Limitar historial en contexto a últimos N turnos	20–40% en input
Voz solo en Plus+ (sin fallback ElevenLabs en Free)	Elimina mayor COGS variable
Rate-limiting conservador en Free	Protege contra abuso
Gemini para Free (ya en código)	~33% vs GPT-4o-mini

Cálculos: gpt-4o-mini \$0.15/1M in · \$0.60/1M out · Gemini 2.0 Flash \$0.10/1M in · \$0.40/1M out · ElevenLabs eleven_v3 ~\$0.0002/char · Supabase Free hasta 50k MAU · \$17.50 MXN/USD · Mayo 2026