

COUNCILia

Operaciones

Costos, modelo de negocio, contenido sensible y métricas.

- Costo por sesión
- Modelo de negocio
- Política de contenido sensible
- Métricas de validación
- Hipótesis de validación

Tabla de contenidos

1 Costo por sesión

2 Modelo de negocio

3 Política de contenido sensible

4 Métricas de validación

Costos por sesión, modelo de negocio, política de contenido sensible y métricas de validación. Todo lo que necesita estar en su sitio antes del lanzamiento aunque no sea visible en la UI. Documento 7 de la serie del MVP v1.1.

Documentos legales correlativos: Términos (10), Privacidad (12), Cookies (13). Este documento resume decisiones operativas; la redacción jurídica detallada va en esos tres.

1. Costo por sesión

1.1 Estimación realista

Una sesión típica del MVP implica:

- **3 llamadas paralelas** (postura inicial, ~250 tokens out cada una).
- **1 llamada de réplica** (~250 tokens out).
- **1 llamada de síntesis** (~400 tokens out).
- **Input acumulado** que crece con el contexto: ~3–8k tokens en total.

Total realista por sesión completa con Claude Sonnet:

- **Tokens:** 15–25k (input + output combinados).
- **Costo:** ~\$0.10–0.20 USD por sesión.

Esto es **2–3× más alto** que el estimado del MVP original. Es importante modelarlo correctamente desde el inicio para no caer en el error clásico de subestimar el costo unitario.

1.2 Qué hacer si el costo sube

Tres palancas, en este orden de preferencia:

1. **Reducir el output** de cada postura inicial (de 250 a 180 tokens). Impacto: ~20% menos costo, riesgo bajo si los prompts están bien apretados.
2. **Quitar la réplica cuando el Tension Detector tiene confianza baja**. Impacto: ~15% menos costo en sesiones donde no agrega valor.
3. **Cambiar a un modelo más barato para postura inicial**, manteniendo Sonnet para la síntesis. Impacto: hasta 40% menos costo, requiere validar calidad.

2. Modelo de negocio

El modelo es freemium con dos tiers en el MVP y un tercero post-validación:

- **Tier gratuito: 5 sesiones / mes.** Suficiente para que el usuario sienta el producto, no suficiente para reemplazar el hábito sin pagar.
- **Tier pro:** sesiones ilimitadas, councils guardables, exportación de síntesis a PDF y markdown. Precio objetivo \$9–15 USD / mes.
- **Tier equipo (v1.3+):** councils compartidos, comentarios sobre síntesis, integración Slack / Notion.

*Regla operativa: el límite del freemium es **por sesiones, no por mensajes**. Cada sesión es la unidad de valor del producto. Limitar por mensajes empuja al usuario a alargar sesiones artificialmente y rompe la dinámica.*

2.1 Cuándo se cobra

El usuario llega al paywall cuando intenta abrir su **sexta sesión del mes natural**. No al final de la quinta. Eso evita el efecto "el producto se cortó cuando estaba en el mejor momento", que es la peor experiencia de paywall.

Una sesión se considera *consumida* solo cuando el usuario envía el primer mensaje al council. Abrir y no escribir no cuenta. Esto se documenta también en los Términos para alinear expectativa.

Se envían avisos por correo al alcanzar la **cuarta y quinta** sesión del mes para que el usuario no se sorprenda con el paywall.

2.2 Reembolsos y prueba

- **Periodo de prueba de 14 días naturales** desde la primera contratación del tier pro: reembolso total a petición, sin justificación.
- Después de los 14 días: no se reembolsa el periodo en curso salvo obligación legal local.
- **SLA de disponibilidad:** si el Servicio queda inoperativo por más de **72 horas seguidas** por causa atribuible a nosotros, se reembolsa prorrateado el periodo afectado.

2.3 Lo que NO se mete al freemium

- **Sin anuncios.** La promesa del producto es íntima; los ads la rompen.
- **Sin venta de datos.** Se dice explícitamente en la página de pricing.
- **Sin "freemium con feature gating molesto"** (tipo: usa, pero la síntesis sale truncada). Es mejor un límite duro y limpio que un producto degradado.

3. Política de contenido sensible

El producto invita a hablar de decisiones reales y a veces dolorosas: relaciones, salud financiera, salud mental. **No tener una política aquí no es una opción** — es responsabilidad básica.

3.1 Reglas para los agentes

- Ningún agente da consejo médico, legal o financiero específico ("compra X", "deja a Y", "toma este medicamento"). Hablan en marco general y devuelven el poder al usuario.
- Los agentes **nunca** sugieren al usuario que "se quede" o "se vaya" de una situación de violencia, ni minimizan abuso.
- Si los agentes detectan ambigüedad sobre violencia o abuso en el relato del usuario, **no asumen**: piden clarificación en una pregunta empática y única, sin moralizar.

3.2 Modo Soporte

Si el mensaje del usuario contiene señales de **crisis emocional aguda, ideación suicida o autolesión**, el orquestador **interrumpe el flujo deliberativo** y entra en modo Soporte:

1. Una sola respuesta empática del **sistema** (no de los agentes), redactada y validada por humanos, no generada en tiempo real.
2. Recursos profesionales según país detectado por idioma o configuración del usuario (líneas de crisis verificadas).
3. El usuario puede continuar la conversación deliberativa **solo si confirma explícitamente** que quiere hacerlo.

La detección es por una combinación de **keywords + clasificador ligero**, ejecutada **antes** del Intent Calibrator. Si el clasificador tiene dudas, manda al modo Soporte: el costo del falso positivo (una pantalla extra) es muchísimo menor que el del falso negativo.

3.3 Edad mínima y cuentas

- **Edad mínima:** 16 años cumplidos. Entre 16 y 18 (o mayoría de edad local) se requiere consentimiento de tutor.
- **No se recopilan a sabiendas** datos de menores de 16 años. Si se detecta una cuenta de menor, se cierra y borra en máximo 7 días naturales.
- **Una persona, una cuenta.** No se permite compartir cuentas.

3.4 Datos personales y retención

- La encuesta de onboarding y el contenido de la conversación se guardan **cifrados en reposo** mediante Supabase row-level security.

- El usuario puede **borrar una conversación individual o todo su historial** desde ajustes (DSAR autoservicio).
- **No se entrenan modelos** con conversaciones de usuarios. Esto se promete explícitamente en términos y en pricing.
- Las conversaciones eliminadas se borran de la base de datos en un máximo de **7 días naturales** (incluyendo backups).

Plazos de retención por tipo de dato:

Tipo de dato	Retención
Cuenta activa	Mientras esté activa
Conversación no borrada	Mientras la cuenta esté activa
Conversación borrada por el usuario	≤ 7 días naturales (incluye backups)
Cuenta cerrada por el usuario	Borrado total en ≤ 7 días naturales
Cuenta cerrada por inactividad (> 24 meses sin login)	Aviso previo por correo + cierre y borrado en 30 días
Logs de seguridad y auditoría	12 meses, anonimizados después
IP completa	≤ 30 días salvo obligación legal
Información de facturación	Plazo mínimo de la ley fiscal aplicable

3.5 Proveedores que tocan los datos

Para mantener consistencia con los Términos (documento 10), la lista de subprocesadores autorizados en el MVP es:

Proveedor	Para qué
Anthropic (Claude API)	Generación de respuestas de los agentes. Acuerdo comercial garantiza que los datos no se usan para entrenar sus modelos.
Supabase	Base de datos y autenticación.
Vercel	Hosting de la aplicación.
Stripe (u otro procesador)	Procesamiento de pagos del tier pro (no se almacenan números completos de tarjeta).
Resend (o equivalente)	Correos transaccionales (recuperación, paywall warnings, avisos).

Cualquier subprocesador adicional necesita actualización notificada en los Términos al menos **30 días antes** de su entrada en operación.

4. Métricas de validación

No medimos si la IA "sabe más". Medimos si la experiencia se siente **cognitivamente diferente**.

4.1 Métricas cualitativas (encuesta post-sesión, opt-in)

- ¿El usuario siente que pensó desde ángulos que no habría considerado solo?
- Claridad percibida después de la conversación (escala 1–5).
- Confianza en la decisión después de consultar al council (escala 1–5).
- ¿Recomendaría el council a alguien con una decisión parecida?

4.2 Métricas cuantitativas (instrumentadas)

- **Tasa de finalización:** % de sesiones donde el usuario llega a pedir síntesis.
- **Retorno a 7 días:** % de usuarios que abren una segunda sesión dentro de la semana.
- **Profundidad por sesión:** mensajes de usuario por sesión (proxy de engagement).
- **Tasa de "esto me cambió la perspectiva":** opt-in en el cierre, una pregunta sí/no.
- **Tiempo a primera postura:** latencia desde envío del mensaje hasta primer token visible (proxy de UX).

4.3 Hipótesis de validación

*Si **tasa de finalización** $\geq 60\%$ y **retorno a 7 días** $\geq 25\%$, el producto funciona y procedemos a v1.2.*

Si está por debajo, el problema es del flujo o de los agentes, no del marketing. Iteramos el MVP otra vuelta antes de añadir features.

Este umbral se fija **antes** de empezar las pruebas con usuarios. Mover el umbral después de ver los datos es la forma estándar de auto-engañarse.